

Challenge – Visualisation d’une base de données de films

Méthodologie


Le projet a débuté par la lecture de l’énoncé des objectifs (SOP) et le téléchargement du fichier CSV. Jupyter Lab a été utilisé avec les bibliothèques standard — Pandas, Matplotlib, Seaborn, SciPy et Statsmodels — pour le chargement, la conversion des types, le nettoyage des données et l’analyse exploratoire (EDA). Les valeurs manquantes (NaN, NaT) ont été identifiées et exclues.


Remarque : Le champ « Title » reste suspect — un modèle OCR/multimodal (ex. : glm-ocr) pourrait le valider par rapport au CSV. Les valeurs manquantes dans le champ « Overview » pourraient être récupérées via des appels API à un LLM combinés à des recherches web.

Les images des affiches ont été téléchargées de manière asynchrone avec httpx et asyncio (plus efficace que la bibliothèque requests). Après l’EDA, Streamlit a été retenu pour l’interface utilisateur plutôt que Gradio, aucun modèle ML n’étant déployé (Gradio convient mieux à l’affichage des métriques de performance de modèles). Un code Gradio initial produisait un rendu médiocre ; le modèle Qwen d’Alibaba a donc été consulté pour affiner la mise en page Streamlit, en prenant le notebook Jupyter comme référence.

Fonctionnalités principales


L’interface affiche les films avec des options de tri : Popularité (par défaut), Moyenne des votes, Nombre de votes et Date de sortie. Des filtres supplémentaires permettent de restreindre les résultats par année, genre, seuil de popularité et nombre de résultats affichés. Un onglet Classement facilite la sélection rapide des meilleurs films, et un onglet Statistiques offre une analyse approfondie du jeu de données. Seules les données nettoyées sont affichées dans l’interface ; les enregistrements incohérents sont examinés dans le notebook Jupyter.





Reproductibilité du code

Un fichier README.md a été fourni, détaillant la configuration de l'environnement, les étapes d'exécution du code et l'accès à l'interface. Le notebook Jupyter exploratoire est également inclus pour révision. L'ensemble du code est disponible à : <https://github.com/agarwalamit081/movie-analysis>.



Limites et améliorations possibles

Le SOP et le périmètre des travaux (SOW) nécessitent une définition plus précise ; selon les besoins métier, des modèles de classification ou de régression pourraient être développés. Les définitions des colonnes, les techniques d'échantillonnage et les informations sur l'équilibre des classes sont absentes — les données présentent une asymétrie (davantage de films après 2000 ; Vote_Count et Popularité sont biaisés), ce qui limite leur utilisation directe dans des modèles ML. L'imputation automatisée par IA pourrait combler les données manquantes. Enfin, aucune conteneurisation (Docker) n'a été mise en œuvre, le projet ne comportant qu'un petit nombre de scripts. Les méthodes Text2sql et les requêtes assistées par la voix peuvent être utilisées conjointement avec des LLM multimodaux pour rendre l'application plus interactive.